

Guide de soutenance — Voyage Assistant

SAE2 BUT3

Encadrement : Bilal Faye (LIPN, CNRS UMR 7030) — Promotion 2025–2026

Démo : <https://optimalako-voyage-assistant.hf.space>

Table des matières

1	Principe de la soutenance	2
2	Répartition (équilibrée) et déroulé	2
3	Plan diapositive par diapositive	2
4	Antisèche : expliquer simplement (jury non-IA)	4
5	Questions probables du jury et réponses	4
6	Conseils pratiques	4

1 Principe de la soutenance

Durée visée : **15 à 20 minutes** de présentation + questions. L'objectif est que le **jury, sans formation en IA**, comprenne ce que fait l'application et pourquoi nos choix techniques sont pertinents. Trois règles :

- **Montrer avant d'expliquer** : on commence par une démonstration concrète.
- **Vulgariser** : chaque terme technique (RAG, embeddings, NER) est expliqué par une image simple avant le mot savant.
- **Équilibre** : chaque membre présente **environ 3 diapositives**, soit un temps de parole comparable.

2 Répartition (équilibrée) et déroulé

Membre	Rôle dans la soutenance	Diapos
Dhanoush Kessavane	Introduction + vidéo de démonstration + front-end	1 à 3
Carl Similien	Architecture, API et base de données	4 à 6
Noé Cervera	Le « cerveau » : LLM, RAG, embeddings, NER	7 à 9
Ako Christian	Actions réelles, sources de vérité, déploiement	10 à 12

Dhanoush ouvre avec une **vidéo de test** de l'application (réalisée avant la soutenance), puis présente brièvement le front-end ; on enchaîne ensuite sur les autres membres. Chacun conclut sa partie en annonçant le suivant.

3 Plan diapositive par diapositive

Pour chaque diapositive : le **titre**, le **contenu** à afficher (3–5 puces maximum, peu de texte), et l'**orateur**.

Partie Dhanoush — Introduction & démo

Diapo 1 — Page de titre. Titre « Voyage Assistant », sous-titre « Assistant IA pour le transport », les 4 noms, l'encadrant, l'URL de la démo. *Dit* : qui nous sommes, le sujet en une phrase.

Diapo 2 — Démonstration (vidéo). La vidéo de test : une recherche de trajet, une réservation, puis une question à l'assistant (ex. « combien de temps dure mon vol ? ») et une modification de billet. *Dit* : « Voici l'application en conditions réelles » ; commenter la vidéo en direct.

Diapo 3 — L'expérience utilisateur (front-end). React, design clair/sombre, **responsive** (mobile/tablette/ordinateur), **multilingue** (FR/EN/ES), **voix** (dictée + lecture). *Dit* : comment l'interface a été pensée pour être simple et accessible.

Partie Carl — Architecture & données

Diapo 4 — Architecture full-stack. Schéma : navigateur (React) → API (FastAPI) → base de données ; couche IA côté serveur. *Dit* : le rôle de chaque brique, le découpage front/back.

Diapo 5 — L’API et la base de données. FastAPI, validation Pydantic, ORM SQLAlchemy ; tables `users`, `trajets`, `billets`, `reclamations`, `chat_sessions`. Catalogue de **plus de 182 000 liaisons** réelles (avion, train, bateau, bus). *Dit* : on manipule de vraies données, pas des exemples.

Diapo 6 — Sécurité et robustesse. Requêtes SQL paramétrées (anti-injection), échappement HTML (anti-XSS), garde-fous contre insultes et injections de prompt, vérification d’identité, secrets hors du code. *Dit* : une application sérieuse doit aussi être sûre.

Partie Noé — Le cerveau (à vulgariser++)

Diapo 7 — Pourquoi un LLM ne suffit pas. Un LLM (Gemini) écrit très bien mais **invente** parfois et ne connaît ni nos données ni l’actualité. *Image* : « un élève brillant mais qui répond de mémoire ». *Dit* : d’où la nécessité du RAG.

Diapo 8 — RAG et embeddings (le cœur du cours). RAG = « examen à livre ouvert » : on **cherche le bon passage** puis on répond. Les **embeddings** transforment le sens d’une phrase en nombres ; deux phrases proches par le sens ont des nombres proches (« je veux annuler » $\approx$ « conditions de résiliation »). Outils : FAISS (recherche rapide), puis un **reranker** qui re-classe les meilleurs résultats. *Dit* : c’est ce qui rend les réponses fiables.

Diapo 9 — Comprendre l’utilisateur (NER) et qualité. Le **NER** repère automatiquement le nom/prénom dans une phrase libre. On évoque l’évaluation : on a testé les réponses (factuelles, anti-hallucination, robustesse aux abus). *Dit* : l’IA est mesurée, pas juste « branchée ».

Partie Christian — Actions réelles & mise en ligne

Diapo 10 — L’assistant agit vraiment. Modifier / annuler / réclamer passent par une **machine à états** déterministe (intention → vérification d’identité → action en base → e-mail + billet PDF). *Dit* : le LLM **rédige**, le code **exécute** — aucune action inventée.

Diapo 11 — Les 3 sources de vérité + déploiement. RAG (règles), base de données (billet personnel, calcul de durée), APIs temps réel (météo, heure, change). Déploiement réel sur **Hugging Face Spaces** + base **Neon**. *Dit* : l’application est en ligne et fonctionne.

Diapo 12 — Bilan et perspectives. Toutes les exigences du sujet sont couvertes (tableau) ; bonus : multilingue, voix, recherche web. Perspectives : plus de documents RAG, notifications, intégration continue. *Dit* : on conclut et on ouvre les questions.

4 Antisèche : expliquer simplement (jury non-IA)

Terme	Phrase à dire
LLM	« Une IA qui écrit du texte, comme un correspondant très cultivé, mais qui peut se tromper s'il répond de mémoire. »
RAG	« On lui fait passer un examen à livre ouvert : on lui met le bon document sous les yeux avant qu'il réponde. »
Embeddings	« On transforme le sens des phrases en nombres, pour que l'ordinateur retrouve les idées proches même sans les mêmes mots. »
FAISS	« Un moteur qui retrouve très vite les passages les plus proches. »
Reranker	« Un second lecteur, plus lent mais plus fin, qui re-classe les meilleurs résultats. »
NER	« Une brique qui repère automatiquement le nom et le prénom dans une phrase. »
Machine à états	« Un parcours guidé et sûr : l'IA ne décide pas toute seule d'annuler un billet, c'est notre programme qui le fait, étape par étape. »

5 Questions probables du jury et réponses

- « **Comment évitez-vous que l'IA invente ?** » — On sépare la rédaction (le LLM) de l'exécution (notre code) ; et pour les questions, on lui fournit la bonne source (RAG, base, API) au lieu de le laisser deviner.
- « **Le RAG, c'est imposé par le cours, qu'avez-vous fait exactement ?** » — Une chaîne vectorielle complète : découpage en *chunks*, embeddings `gte-small` en local, index FAISS, puis reranking par cross-encoder.
- « **Vos données sont-elles réelles ?** » — Oui : plus de 182 000 liaisons (avion, train, bateau, bus) ; les billets, comptes et conversations sont stockés en base PostgreSQL.
- « **Y a-t-il des données pour le bus et le bateau ?** » — Oui, tous les modes sont présents (l'avion et le train sont les plus fournis ; le bus et le bateau ont des catalogues plus petits mais réels et réservables).
- « **Est-ce vraiment en ligne ?** » — Oui, sur Hugging Face Spaces avec une base Neon ; on peut le montrer en direct (prévoir le réveil du Space, ~30 s).
- « **Pourquoi pas un hébergeur classique ?** » — Le RAG charge deux modèles en mémoire (~1 Go) ; les offres gratuites à 512 Mo plantent, d'où Hugging Face (16 Go).
- « **Comment gérez-vous plusieurs langues ?** » — L'interface est traduite (FR/EN/ES) et l'assistant reçoit une consigne de langue pour répondre dans la langue choisie.
- « **Sécurité ?** » — SQL paramétré, échappement HTML, garde-fous contre injections de prompt et abus, vérification d'identité, secrets hors du code.

6 Conseils pratiques

- Réveiller le Space **avant** de passer (premier accès ~30 s).
- Avoir la **vidéo de démo en local** (secours si le réseau flanche).
- Peu de texte par diapo : on **parle**, la diapo **appuie**.
- Préparer un billet de test (numéro + identité) pour la démo de modification.

— Chronométrer : $\sim 3\text{--}4$ min par personne.